CRISP-DM 分析流程

從商業理解到部署上線，六階段閉環迭代的多元線性迴歸流程

5 種選取演算法 × 4 種 k　1-SE 奧卡姆剃刀選模　Flood (大數據) / Automobile (小樣本)

01 BUSINESS UNDERSTANDING

商業理解

明確定義預測目標、研究問題及評估成功標準。

- **預測標的**：Flood (洪水機率) / Automobile (車輛價格)
- **評估指標**：R^2 (決定係數)、RMSE (均方根誤差)、MAE
- **商業導向**：Kaggle 競賽以 R^2 為主；工程部署兼顧誤差尺度與可解釋性

階段產出　問題定義矩陣、評估指標定義與 Baseline 基準線

02 DATA UNDERSTANDING

資料理解

探索資料分布、特徵品質與潛在資料洩漏風險。

- **資料探索**：檢視欄位型態、缺失值模式、離群值與重複樣本
- **目標分布**：分析目標變數偏態，繪製分佈直方圖與 KDE 密度圖
- **一致性檢驗**：比對訓練集與獨立測試集分布差異，防範分佈偏移

階段產出　EDA 探索報告、目標分布圖 (target_distribution.png)

03 DATA PREPARATION

資料準備

構建嚴格隔離測試集之前處理與特徵工程管線。

- **嚴格切分**：Fit (60%) / Validation (15%) / Calibration (10%) / Test (15%)
- **資料前處理**：中位數補值、StandardScaler（僅於訓練集 fit，杜絕洩漏）
- **特徵工程**：Flood 新增 10 組相乘交互項；Auto 採 One-Hot 虛擬變數

階段產出　Flood 30 個 / Auto 63 個前處理後候選特徵資料流

管線推進

未達標回饋

模型部署

04 MODELING

模型建立

比較 5 大特徵選取演算法，訓練多元線性迴歸模型。

- **選取方法**：SelectKBest、RFE、Sequential (SFS)、Lasso、Permutation
- **特徵網格**：Flood $k \in [14, 20, 25, 30]$；Auto $k \in [8, 16, 24, 32]$
- **模型配適**：以 OLS 多元線性迴歸擬合，保證特徵係數直接具備物理可解釋性

階段產出　每資料集 20 組完整實驗模型、特徵係數與訓練指標

05 EVALUATION

模型評估

以驗證集 1-SE 規則選模，並以獨立測試集確認泛化力。

- **1-SE 選模**：門檻 = 最小 RMSE + 1×SE，門檻內挑選特徵數最少之精簡模型
- **獨立評估**：測試集評估 Test RMSE、MAE、R^2，並繪製殘差診斷圖
- **不確定性**：95% Split Conformal 預測區間，給出有限樣本邊際覆蓋保證

階段產出　最佳精簡模型 (RFE k=20)、不確定性量化指標與診斷圖

06 DEPLOYMENT

部署上線

封裝模型資產，打造零後端、即時推論之互動式網頁。

- **模型打包**：匯出 joblib 二進位檔、best_features.json 與實驗總表 CSV
- **前端交付**：Chart.js 響應式儀表板，支援切換資料集、即時試算預測機率/價格
- **競賽交付**：自動對齊官方格式產出 Kaggle submission.csv

階段產出　GitHub Pages 靜態網站、Python 重現腳本與提交成果物

迭代回饋閉環機制 (Iterative Feedback)

CRISP-DM 具高度迭代性。若 Evaluation 階段發現殘差具異分散性或模型欠擬合，流程立即回流至 Data Preparation 重構特徵，或調整 Modeling 正則化參數，非單向瀑布。

雙向資料集規模驗證 (Dual Datasets)

本專案涵蓋百萬級巨量線性資料集 (Flood Prediction，1.12M 筆) 與小樣本高維類別資料集 (Automobile，201 筆)，全面檢驗多元線性迴歸流程在極端資料情境下的穩健性。

嚴格無洩漏與可重現性 (Reproducibility)

全流程固定 random_state=42；特徵選擇演算法與前處理器嚴格僅使用訓練資料 (Fit split) 進行統計擬合，Validation/Calibration/Test 完全隔離，達到正式工程可重現標準。

模型預測結果

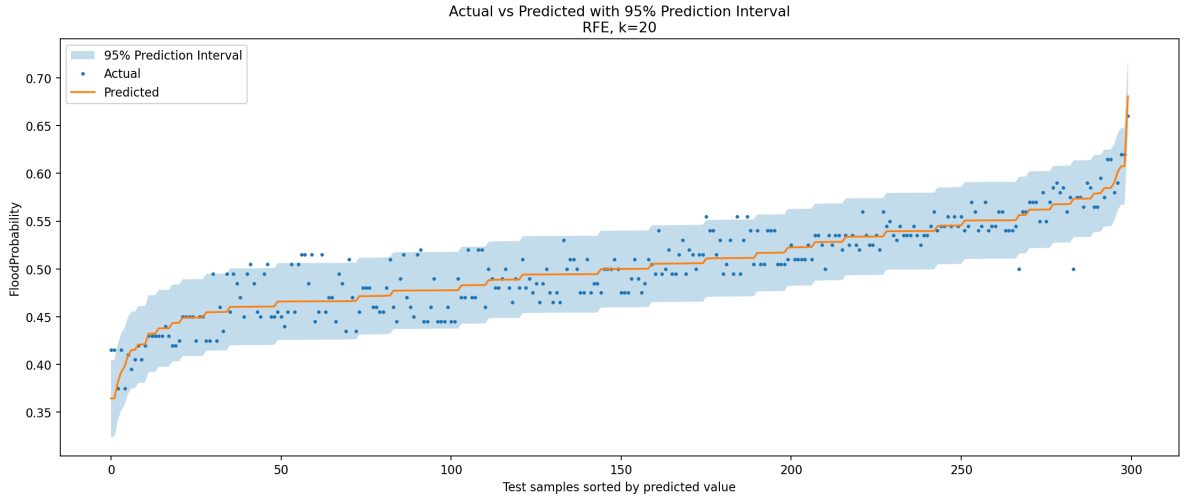
Flood Prediction · RFE k=20 · 1-SE 最佳選模 · 獨立 Test Set (n=167,694) 泛化評估

Test n = 167,694 | PI 覆蓋率 95.06% | 1-SE 最佳模型

TEST RMSE	TEST MAE	TEST R²	95% PI COVERAGE	CONFORMAL Q̂	MEAN PI WIDTH
0.020083	**0.015803**	**0.8448**	**95.06%**	**0.0402**	**0.0803**
均方根誤差 (越低越好)	平均絕對誤差	解釋 84.48% 變異 (競賽主指標)	名目目標 95% (Conformal)	校準集絕對殘差分位數	平均預測區間帶寬 (窄且精確)

Actual vs Predicted · 95% Prediction Interval (95% 預測區間圖)

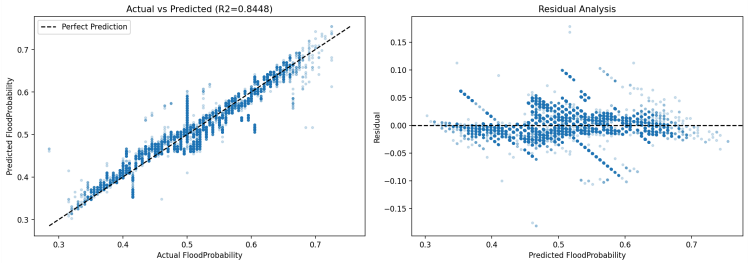
Test 排序抽樣 300 筆



解讀分析：測試集樣本依預測值由小到大排序；深藍點為實際觀測值，橘線為線性迴歸預測值，淺藍色帶為 95% Split Conformal 預測區間。實際點群均勻坐落在帶內，實測覆蓋率達 95.06%，精準符合名目要求。

Parity Plot (對角配適) & Residual Analysis (殘差圖)

殘差對稱無偏



解讀分析：左圖實際值對預測值緊貼對角虛線（R^2=0.8448）；右圖殘差均勻對稱散布於零軸兩側，未出現漏斗狀異分散性或曲線彎曲，證明多元線性迴歸滿足同分散與無偏假設。

泛化能力驗證
Validation ≈ Test

Validation RMSE (0.020089) 與 Test RMSE (0.020083) 差距僅 0.003%，顯示模型完全無過擬合，泛化表現卓越。

不確定性量化
Conformal 覆蓋保證

採用 Split Conformal Prediction，在無殘差常態分布假設下提供有限樣本邊際保證，測試集覆蓋率 95.06% 精準達標。

線性假設診斷
殘差分布對稱

殘差散佈圖呈現理想白雜訊特性，無明顯系統性彎曲或異常群聚，證明 20 個原始特徵與洪水機率呈極高度線性相關。

選模架構優勢
精簡 20 特徵勝出

RFE k=20 成功剔除 10 組非必要交互作用特徵，模型更精簡、推論更快，且完全保證線性參數模型之純粹物理可解釋性。

評估依據：Multiple Linear Regression · RFE k=20 (1-SE 最佳模型) · 獨立測試集 n=167,694 一次性獨立驗證

特徵選擇比較

5 種方法 × 4 種特徵數 · 以 Validation RMSE 與 1-SE 規則選模之全方位實證比較

20 組全網格實驗 | 1-SE 最終勝出：RFE k=20 | 精簡 33.3% 特徵

Validation RMSE 實驗矩陣熱圖 · 數值越低越好

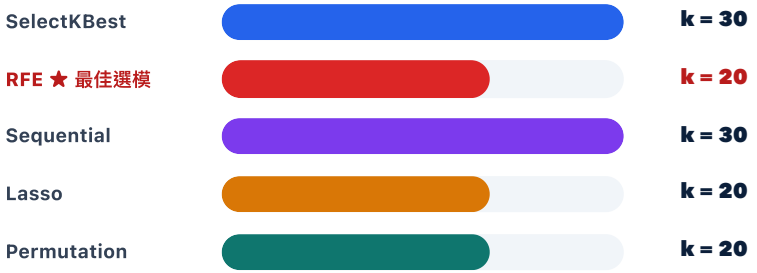
藍色外框標記為 1-SE 最終推薦組合

方法	k = 14	k = 20	k = 25	k = 30	1-SE k
SelectKBest	0.033791	0.029557	0.024492	0.020088	k = 30
RFE	0.034145	0.020089 (1-SE 最佳)	0.020089	0.020088	k = 20
Sequential	0.023111	0.022100	0.021120	0.020088	k = 30
Lasso	0.034268	0.020089	0.020089	0.020088	k = 20
Permutation	0.034242	0.020089	0.020089	0.020088	k = 20

最低 RMSE (表現最佳) — 最高 RMSE (表現較差)

1-SE 規則選出之精簡特徵數

奧卡姆剃刀原則



決策結論：最終選擇 **RFE k=20**。其 Validation RMSE 為 0.0200894，與全特徵最小 RMSE (0.0200878) 差距僅 0.0000016，完全落在 1-SE 門檻之內，但特徵數從 30 減少至 20（精簡 33.3%），完全免除額外維護 10 個非必要交互作用項。

SelectKBest

以 F-test 單變量回歸獨立選取分數最高的前 k 個特徵；運算極快，但忽略特徵間共線性與組合交互作用。

RFE (遞迴消除)

以 LinearRegression 權重反覆遞迴剃除貢獻最小特徵；能有效捕捉特徵間群體共變效果，選模表現最穩。

Sequential (SFS)

前向逐步貪婪加入使交叉驗證 RMSE 降幅最大之特徵；演算法嚴謹，但運算成本最高，採訓練子樣本加速。

Lasso (L1 正則)

透過 LassoCV 交叉驗證選取最適懲罰係數 α，依係數絕對值大小排序選取前 k 個，天然具備稀疏性選擇能力。

Permutation

隨機打亂單一特徵順序並衡量模型驗證誤差上升幅度；最真實反映特徵邊際價值，不受線性權重縮放影響。

① 絕對最小 Validation RMSE

SelectKBest k=30 =
0.020087766
（需使用全滿 30 個特徵，包含 10 個計算繁瑣的非必要交互項）

② 1-SE 統計等價門檻

0.020087766 + 0.000043670 (SE) =
0.020131436
（在此門檻內的模型皆視為統計無顯著差異）

③ 1-SE 最佳勝出：RFE k=20

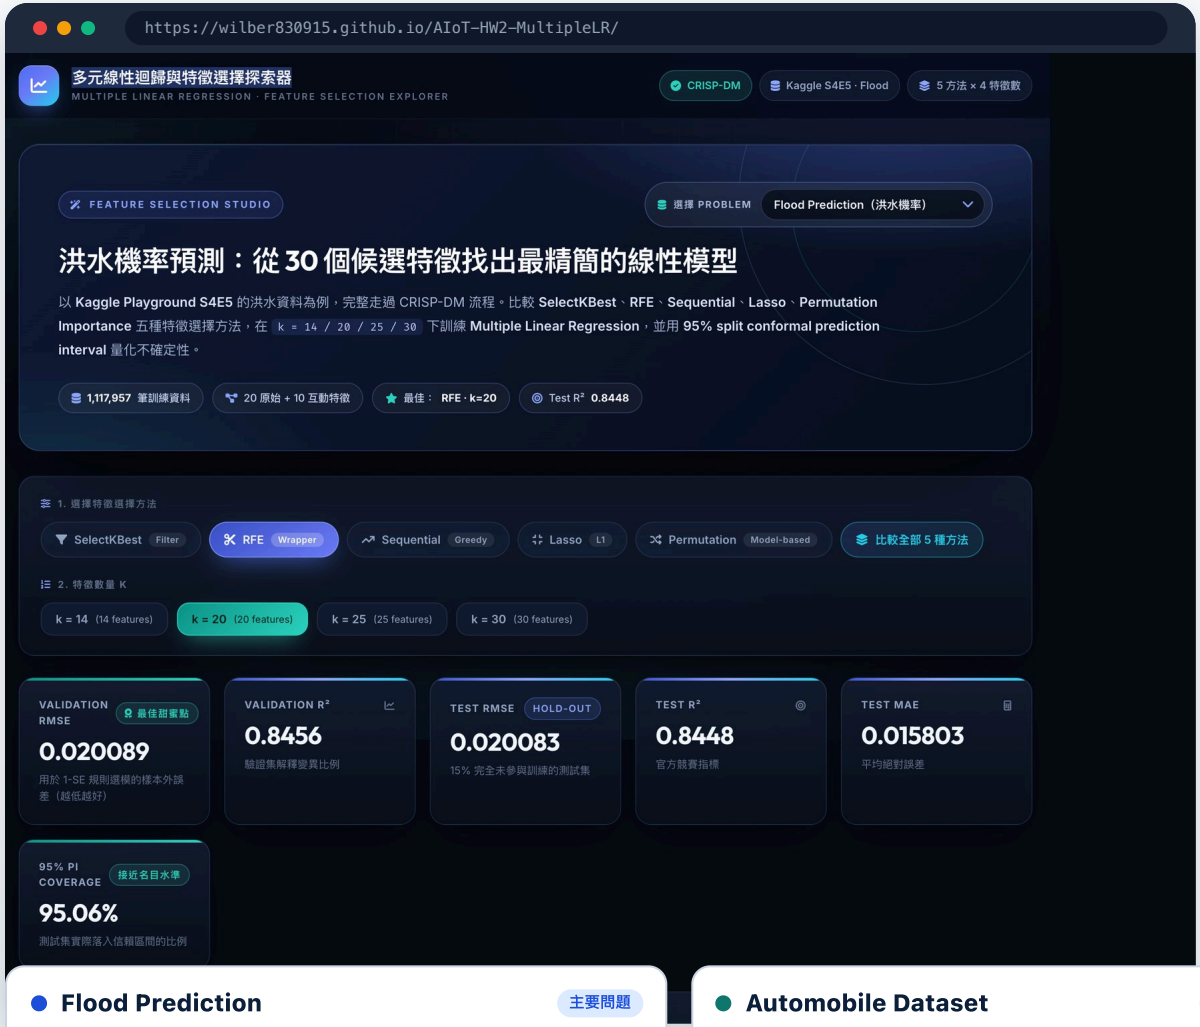
Validation RMSE =
0.020089362
，低於 1-SE 門檻且特徵數最精簡，成功捨棄 10 個交互項！

資料依據：outputs/feature_selection_comparison.csv、model_data.js · 數值取自實際 20 組實驗運行輸出

專案總覽

Multiple Linear Regression · Feature Selection Explorer · 響應式互動靜態儀表板

GitHub Pages 靜態部署 | 2 大對照問題 | 純前端無伺服器架構



2
Problems (Flood/Auto)

5
特徵選取演算法

4
k 值階梯 / 方法

40
組全網格模型實驗

1-SE
精簡選模規則

95%
Conformal 預測區間

⚙ 端到端工程管線與部署架構 (Data Pipeline)

data/ 原始 CSV → Python main.py 實驗 → model_data.js 靜態資料 → Chart.js 前端視覺化 → GitHub Pages 上線

● Flood Prediction — 主要問題

1,117,957
訓練樣本數

30
候選特徵總數

RFE k=20
1-SE 最佳配置

0.8448
Test R² (競賽指標)

20 原始特徵 + 10 交互特徵；Test RMSE 0.020083、MAE 0.015803、PI 覆蓋率 95.06%。大數據高線性問題，20 個原始特徵即達飽和表現。

● Automobile Dataset — 第二 Problem

201
有效樣本數

63
候選特徵總數

Sequential k=16
1-SE 最佳配置

0.8310
Test R² (測試集)

15 數值 + 10 類別特徵 (One-Hot 編碼)；Test RMSE 4,887.99、MAE 3,543.53、PI 覆蓋率 93.55%。小樣本高維度，1-SE 特徵減半使 Test R² 由 0.753 升至 0.831！

技術棧、交付與重要限制

Python 3.10 | pandas | NumPy | scikit-learn | statsmodels | Matplotlib | Chart.js | HTML5/CSS3 | GitHub Pages

成果交付：互動儀表板、Python 流程、README、Kaggle 提交檔、PDF 報告

ChatGPT 建議與限制：① 合成資料高 R² 不保證實務因果關係；② Auto 測試集僅 31 筆，預測區間較寬 (q̂≈$10,584)，反映小數據真實不確定性；③ SFS 採抽樣以維持運算效率。